

郑州大学

硕士学位论文

基于灰色神经网络的股票分析预测研究

姓名：王志远

申请学位级别：硕士

专业：计算机软件与理论

指导教师：王世卿

201105

摘 要

随着社会经济的发展，股票已经成为人们投资理财的重要工具之一。股票指数综合反映了股票市场上股票的总体波动情况，股票指数预测对于投资者作出合理的决策具有重要的指导意义。然而股票市场是一个复杂的非线性系统，利用传统的统计分析方法和时间序列预测技术很难准确的反映股票市场的特点，而神经网络和支持向量机等智能方法通常需要较多的样本数据。由于组合模型可以结合模型的优点、克服模型的缺点，因而成为研究的热点。

灰色神经网络模型是 GM (1, N) 模型和 BP 神经网络模型的组合模型，它结合了神经网络和灰色系统模型各自的优点，可以在少数据基础上提高预测的精度。本文运用灰色神经网络对上证综指进行了预测研究，分别建立了股票指数的日收盘指数、周收盘指数和月收盘指数的预测模型。通过对上证综指的日收盘指数、周收盘指数、月收盘指数的短期预测研究发现，随着预测时间跨度的增大，预测误差有逐渐加大的趋势，这是由于随着时间跨度的增大，股票指数的波动幅度也加大，而灰色神经网络和 GM (1, N) 模型比较适合对比较平稳的股票市场的预测。灰色神经网络模型比 GM (1, N) 模型的预测精度有所提高。
关键字：股票 预测 灰色系统理论 灰色神经网络

Abstract

With the development of social economy, the stock has become an important investment and financial management tools. Stock Index reflects the overall volatility of the stock on the stock market. Prediction of stock index can help investors to make reasonable decisions . But the stock market is a complex nonlinear system, The traditional methods of statistical analysis and time series prediction is difficult to accurately reflect the characteristics of the stock market. The neural network and support vector machines and other intelligence methods usually require more sample data. For combined models can combine the advantages of the model and overcome the shortcomings of the model, it become a hot research area.

Gray neural network model is the combination of GM (1, N) model and BP neural network model. It combines the advantages of neural networks and the gray system model. It can improve forecast accuracy based on a little data. This paper use gray neural network to predict the Shanghai Composite Index, establish the grey neural network model of the daily close index, weekly close index and monthly close index. It was found that with the predicted time span increases, the prediction error is gradually increasing through the prediction research of the daily close index, weekly close index and monthly close index of the Shanghai Composite Index. This is because that as time span increases the volatility of stock index also increased, The gray neural network and the GM (1, N) model is more suitable for stable stock market prediction. Gray neural network model is better than GM (1, N) in prediction accuracy.

Keywords: stock, prediction, grey system theory, grey neural network

1 绪论

1.1 研究背景及意义

股票价格指数是反映国民宏观经济发展变化的重要参考指标。股票价格指数的运行规律因此也是经济领域研究的热点问题。股票投资已经成为人们日常生活的一个重要组成部分，对股票的短期预测有助于股票投资者作出合理的决策。股票预测的目的在于探索股票行情的发展规律，为股票投资提供科学依据。由于影响股票价格的因素很多，并且我们不能准确把握金融政策、公司状况等因素以及其他不确定因素的变化对股票市场的影响，因而对股票价格走势的准确预测是比较困难的^[1,9]。而对股票投资者来说，对股票价格变化趋势预测的越准确，就可以规避风险，从而对利润的获取也就更容易；对国家的经济发展而言，股票价格指数预测对证券市场实施有效监管也具有重要作用。

自股票市场出现后，人们不断对股票市场进行分析研究，出现了许多有价值的股票分析预测方法。基本分析法和 technical 分析法由于其传统地位和其易操作性，现在仍然被大多数市场人士用以分析预测股票的走势。股票的基本分析法注重对股票的政治因素、经济因素、财务状况等基本面的研究。影响股票基本面的因素有全国的经济环境、企业所属行业的性质和企业经营状况等。股票的技术分析法是对股票的各种图表的技术形态进行研究。基本分析法着重于对总体经济环境、企业所处行业环境和企业经营管理状况进行分析，并据此判断股票的内在价值。而股票的技术分析则是通过对股票的各种图表的技术形态研究股票市场行为，并据以推测股票价格的未来变化发展趋势。基本分析的目的是为了判断股票的价位是否合理并预测股票价格在较长一个时期内的空间，而技术分析主要是预测中、短期内股票价格变化发展的趋势。基本分析法适合对股票价格长期趋势的预测，而技术分析主要适合做中、短期预测。常用的技术指标有移动平均线（MA）、平滑异动平均线（MACD）、能量累积线（OBV）、动量线（MTM）、乖离率（BIAS）等，通常技术分析需要几个指标互相印证才可以做出投资决策。

基本分析法和 technical 分析法在股市预测中有其不可替代的作用，但是也存在明显的不足。基本分析法侧重基本面的分析，但由于信息披露不充分、不完全，还有市场上和企业自身的一些不可测因素，难免对宏观经济环境、行业环境和

企业经营状况的把握有失偏颇。而技术分析法仅侧重于对技术图表的分析, 这些分析法大部分是出于对以往股市运行经验的总结, 在对瞬息万变的股市预测上缺乏足够的说服力。

随着人工智能、数据挖掘等技术的发展, 许多智能方法被用于股票的预测。人工神经网络由于具有自学习、自适应和误差修正等优点, 因而被应用于金融市场的分析和预测。但是这些方法通常需要大量的样本数据用以学习和训练。传统的统计学方法又要求数据服从某种典型的分布。

灰色系统理论是我国学者邓聚龙教授提出的一种对“小样本”、“贫信息”系统建模方法。灰色系统理论建模不需要数据符合典型的分布, 通过对系统行为序列建立灰色模型, 可以预测系统未来的行为序列。经过二十多年的发展, 已逐步形成以灰色序列算子、灰色关联分析、灰色聚类分析、灰色系统模型和灰色预测决策为内容的学科体系和研究方法, 并且已经在工农业许多领域得到广泛的应用。由于股票价格受到经济、政治、人们心理等许多错综复杂因素的影响, 这些因素很难量化, 尤其是我国的股票市场还不健全, 股票的价格也呈现随机游走, 不具备任何统计特征, 不存在某种概率分布形态能描述股票的价格走势, 具有很大的灰色特性, 因此可以建立灰色模型来预测股票的短期走势。国内外已有许多研究者将灰色系统理论应用于股票的分析和预测。

1.2 研究现状

近几年来, 人工智能、灰色系统理论等技术已经逐步被研究者应用于股票市场的分析和预测。

MaRias Schumann (1993) 分别对 ARIMA 模型和神经网络模型在股票预测方面的应用作了研究, 其研究表明, ARIMA 模型的预测结果优于神经网络模型的预测结果^[1]。

Corchado J.、Fyfe C. 和 Lees B. (1998) 在研究中分别用 ARIMA 模型、多层前馈网络模型和径向基函数预测了道琼斯工业指数的走势, 其研究表明 ARIMA 模型的预测结果劣于多层前馈神经网络模型的预测结果, 而优于径向基函数模型的预测结果^[2]。

田盈 (2001) 将灰色灾变预测模型应用于对股市灾变日期序列的预测。作者把个股的历史数据的指标集划分为阳变日期集和阴变日期集, 然后分别对个股

指标集阳变日期集和阴变日期集建立灰色灾变模型，并预测了股票的未来几个灾变日期^[3]。

陈海明、李东(2003)应用灰色系统理论中的数列预测模型对上证综指进行了预测获得了较高的预测精度^[4]。

夏景明、肖冬荣等(2004)对灰色 GM (1, 1) 模型和神经网络模型的组合模型在股票预测中的应用做了研究，研究表明，无论从拟合精度还是从预测精度来看，灰色 GM (1, 1) 与神经网络的组合模型都优于 GM (1, 1) 模型^[5]。

杨成(2005)在研究中比较了多元线性回归模型和神经网络模型在股票价格预测方面的应用，研究结果表明神经网络模型的预测精度高于线性回归模型的预测精度^[6]。

丁霞、肖新平(2008)研究了 GM (0, N) 模型和 GM (1, 1) 模型的组合预测模型。研究表明灰色组合模型的预测精度高于线性回归模型的预测精度^[7]。

综上所述，神经网络模型、灰色系统理论等方法在股票市场的分析预测中已经得到广泛的应用。在预测方法的选取上，国外研究者对股票预测的研究，主要借助于神经网络模型和 ARIMA 模型等方法，而对灰色系统模型预测方法研究的并不多。国内研究者除了对神经网络模型的研究以外，还有许多学者研究了灰色系统模型在股票预测中的应用并取得了良好的预测效果。灰色系统模型不仅能对股票价格指数的未来数值进行预测，还可以预测股票价格指数的灾变日。

1.3 研究内容

灰色理论主要通过对系统已知信息的开发、生成来提取有用的信息，从而实现了对系统的认知。灰色系统模型 (Grey System Model) 是灰色系统理论的核心内容。灰色系统模型具有建模所需信息较小、建模时不必事先知道系统行为序列的分布特征等优点。灰色系统模型在建模时不考虑系统行为序列的分布规律，而是直接从系统的行为序列中找出系统的变化趋势，但是，灰色系统模型没有进行并行计算，其预测精度也不高。BP (Back Propagation) 神经网络是人工神经网络的重要模型之一，可以实现非线性映射，具有很好的并行计算、分布存储、自适应学习功能、容错性和鲁棒性等优点，但 BP 神经网络在网络的训练阶段需要大量的训练样本。灰色神经网络模型融合了二者的优点，可以在少

数据基础上提高预测的精度。

本文改进了灰色神经网络的预测方法，将灰色神经网络应用于股票的短期预测。本文选取了收盘价、开盘价、最高价、最低价、成交量、成交额六项指标，建立灰色神经网络，分别对上证综指的日收盘指数、周收盘指数、月收盘指数进行了短期走势的预测，并将灰色神经网络与 GM (1, N) 模型的预测结果进行了比较。

1.4 本文的主要工作及组织结构

本文主要通过灰色神经网络模型对上证综指日数据、周数据、月数据作出短期预测。论文的组织结构如下：

第一章，绪论。主要介绍了论文的研究背景和意义、股票预测的基本理论以及研究现状、论文的研究内容和组织结构。

第二章，灰色系统理论。主要介绍了灰色系统理论的基本概念、基本原理、主要内容、基本方法以及灰色理论已经或可以应用在股票分析预测方面的方法。

第三章，灰色神经网络模型。分别介绍了人工神经元模型、BP 神经网络模型、GM(1, N) 模型和灰色神经网络模型及灰色神经网络算法步骤。

第四章，灰色神经网络模型在股票预测中的应用主要利用灰色神经网络对上证综指的收盘指数进行了短期预测。论文分别用灰色神经网络对上证综指的日数据、周数据、月数据进行了预测，并将灰色神经网络的预测结果与灰色模型的预测结果进行了比较。实验结果表明，灰色神经网络对上证综指收盘指数的预测在预测精度上比 GM(1, N) 模型有所提高。

第五章是对全文的总结以及对未来研究工作的展望。

2 灰色系统理论

2.1 灰色系统理论

2.1.1 灰色系统基本概念

灰色系统理论与其它理论不同，它是根据颜色命名的^[14]。灰色系统理论研究的是“部分信息已知、部分信息未知”的少数据、不确定系统。它通过对系统已知信息的开发、生成实现对系统的认知。信息不完全的系统（即灰色系统）在现实中式很常见的，例如证券市场中，由于受到利率政策、金融政策、国际市场、政治环境以及企业改革等因素影响，即使最好的分析师也难以准确把握。而灰色系统理论则可以通过对已知信息的生成来研究这些灰色不确定系统。

2.1.2 灰色系统基本原理

在灰色系统理论发展过程中，逐渐总结、提炼出了几条基本原理^[13]。

原理 1 差异是信息。

原理 2 信息不完全系统的解是不唯一的。

原理 3 充分开发、利用已有的“最少信息”。

原理 4 信息是认知事物的根据。

原理 5 新信息在认知中的作用大于老信息。

原理 6 在现实系统中系统的灰性是绝对的。

从以上六条原理，可以看出灰色系统理论是有相当深刻的哲学内涵的。

2.1.3 灰色系统理论的主要内容

灰色系统理论经过二十多年的发展，逐步形成了自己的学科体系和研究方法^[15~23]，其主要研究内容包括灰色序列算子、灰色关联分析、灰色系统模型和灰色聚类评估等。

灰色序列算子理论主要通过一些灰色算子来去除环境对系统的冲击扰动，从而生成系统的灰色序列，实现对系统运行行为的认识和预测，常用的灰色序列算子主要包括有均值生成算子、强化缓冲算子、弱化缓冲算子等^[19, 20]。

灰色关联分析是根据系统行为特征序列曲线之间的几何形状的相似程度来判断系统行为特征序列之间的相互联系的紧密程度^[22]。系统行为特征序列曲线

之间的几何形状越接近，序列之间灰色关联度就越大，序列之间的联系就越紧密。

灰色系统模型是对系统的行为特征序列建模，并对系统序列未来的发展变化趋势进行预测^[8, 11, 12]。灰色系统模型可以对系统特征行为序列建立 GM (1, 1) 模型^[24]。也可以对系统行为序列及其相关序列建立 GM (1, N) 模型或建立 GM 模型群。

灰色聚类评估是指灰数的白化权函数或灰色关联矩阵将观察对象或观测指标分成若干可定义类别的方法。

2.1.4 几种不确定性方法的比较

模糊数学、概率统计和灰色系统理论是在科学研究中三种常用的不确定性问题研究方法,但其研究对象在不确定性上有所区别。

模糊数学主要研究的是在认知过程中存在的不确定问题，这些问题通常内涵是明确的，但其外延却是未知的，如大家都说“青年人”这个词，但这个词到底包含了哪些人则是不确定的。模糊数学对这类认知上的不确定问题主要是借助于隶属函数来对系统不确定信息进行处理。

概率统计研究对象是“随机不确定”对象，其研究对象必须是大样本；概率统计主要研究统计规律，考察具体多种可能性随机事件的每一种结果发生的可能性大小，概率统计要求研究对象服从某种典型的分布。

灰色系统理论主要研究外延明确而内涵未知的“少数据”、“贫信息”不确定系统，其特点是仅需要系统行为序列的极少的数据就可以建模，以上三种常用的不确定方法的比较见表 2.1。

表 2.1 三种不确定方法的比较

项目	模糊数学	概率统计	灰色系统
研究对象	认知不确定	随机不确定	贫信息不确定
基础集合	模糊集	康托尔集	灰色朦胧集
方法依据	映射	映射	信息覆盖
途径手段	截集	频率统计	灰序列算子
数据要求	隶属度可知	典型分别	任意分布
侧重	外延	内涵	内涵

目标 特色	认知表达 凭经验	历史统计规律 大样本	现实规律 小样本
----------	-------------	---------------	-------------

2.2 灰色序列算子

设

$$X=(x(1),x(2),...,x(n))$$

为系统行为特征序列，XD 为 X 经过算子 D 作用后的序列，记为

$$XD=(x(1)d,x(2)d,...,x(n)d)$$

称 D 为系统行为特征序列的序列算子。

常用的弱化算子如下：

平均弱化缓冲算子（AWBO）为：

$$x(k)d=\frac{x(k)+x(k+1)+\cdots+x(n)}{n-k+1},k=1,2,...,n \quad (2-1)$$

加权平均弱化算子（WAWBO）为：

$$x(k)d=\frac{kx(k)+(k+1)x(k+1)+\cdots+nx(n)}{(n+k)(n-k+1)/2},k=1,2,...,n \quad (2-2)$$

当系统行为特征序列 X 为非震荡序列时，

$$x(k)d=\frac{x(1)+x(2)+\cdots+x(k-1)+kx(k)}{2k-1},k=1,2,\cdots,n-1$$

$$x(n)d=x(n) \quad (2-3)$$

为强化算子。

在采集数据时，常因为某些原因导致数据序列出现空穴。或者当系统运行到某个时刻产生异常而导致空穴。这时就可以用均值生成算子来构造新数据，以填补空穴。比较常用的紧邻生成算子为：

$$x^*(k)=0.5x(k+1)+0.5x(k-1)$$

其中 $x^*(k)$ 为紧邻均值生成数。

累加生成是使系统行为序列由灰变白的一种有效方法，通过累加可以使离乱的数据呈现出规律性，因此，累加生成算子对灰色系统建模有举足轻重的作

用。累减生成算子和累加生成算子是互逆的一对算子，累减生成算子可以还原累加生成的序列，从而得到系统行为序列。

设原始序列为

$$X^{(0)} = (x^{(0)}(1), x^{(0)}(2), \dots, x^{(0)}(n)),$$

D 为序列算子，若

$$X^{(0)}D = (x^{(0)}(1)d, x^{(0)}(2)d, \dots, x^{(0)}(n)d)$$

$$x^{(0)}(k)d = \sum_{i=1}^k x^{(0)}(i), k = 1, 2, \dots, n$$

则称 D 为系统行为特征序列的一次累加生成算子 (1-AGO)，记

$$X^{(1)} = X^{(0)}D = (x^{(1)}(1), x^{(1)}(2), \dots, x^{(1)}(n))$$

为系统行为特征序列的一次累加生成序列。

累加生成可以使一次累加序列 $X^{(1)}$ 呈现灰指数律，可以用某个指数函数进行拟合；累加生成算子是灰色模型 (GM) 的基础。

2.3 灰色关联分析

灰色关联分析通过计算系统序列之间的灰色关联度来判断序列间的联系是否紧密。序列之间的灰色关联度越大，序列曲线越接近，序列之间的联系就越紧密。

设 X_i 为系统因素，则称

$$X_i = (x_i(1), x_i(2), \dots, x_i(n))$$

为系统因素 X_i 的行为序列。 X_i 可以为指标序列、时间序列或横向序列，无论是指标序列、时间序列或横向序列都可以用来做灰色关联分析。

若 D 为序列算子且

$$X_iD = (x_i(1)d, x_i(2)d, \dots, x_i(n)d)$$

其中

$$x_i(k)d = \frac{x_i(k)}{x_i(1)}, k = 1, 2, \dots, n$$

则称 D 为初值化算子。利用初值化算子可以使系统的行为序列数据实现无量纲化。

设系统行为序列

$$X_0 = (x_0(1), x_0(2), \dots, x_0(n))$$

$$X_1 = (x_1(1), x_1(2), \dots, x_1(n))$$

.....

$$X_i = (x_i(1), x_i(2), \dots, x_i(n))$$

.....

$$X_m = (x_m(1), x_m(2), \dots, x_m(n))$$

对于 $\xi \in (0,1)$, 令

$$\gamma(x_0(k), x_i(k)) = \frac{\min_i \min_k |x_0(k) - x_i(k)| + \xi \max_i \max_k |x_0(k) - x_i(k)|}{|x_0(k) - x_i(k)| + \max_i \max_k |x_0(k) - x_i(k)|}$$

$$\gamma(X_0, X_i) = \frac{1}{n} \sum_{k=1}^n \gamma(x_0(k), x_i(k)) \quad (2-4)$$

则称 $\gamma(X_0, X_i)$ 为 X_0 与 X_i 的灰色关联度, 记为 γ_{0i} 。 ξ 称为分辨系数。灰色关联度的计算步骤如下:

第 1 步 利用初值化算子求系统行为序列的初值像:

$$X'_i = \frac{X_i}{x_i(1)} = (x'_i(1), x'_i(2), \dots, x'_i(n)), i = 0, 1, 2, \dots, m$$

第 2 步 求系统序列的差值序列:

$$\Delta_i(k) = |x'_0(k) - x'_i(k)|, \Delta_i = (\Delta_i(1), \Delta_i(2), \dots, \Delta_i(n)), i = 0, 1, 2, \dots, m$$

第 3 步 求序列极差, 记:

$$M = \max_i \max_k \Delta_i(k), m = \min_i \min_k \Delta_i(k)$$

第 4 步 求系统行为序列之间的关联系数:

$$\gamma_{0i}(k) = \frac{m + \xi M}{\Delta_i(k) + \xi M}, \xi \in (0,1), k = 0, 1, 2, \dots, n, i = 0, 1, 2, \dots, m$$

第 5 步 求系统序列之间的关联度:

$$\gamma_{0i} = \frac{1}{n} \sum_{k=1}^n \gamma_{0i}(k), \quad i = 0, 1, 2, \dots, m$$

灰色关联分析可以用来描述系统行为序列之间关系的紧密程度。两个序列之间联系越紧密，灰色关联度的值就越大。用灰色关联分析可以根据股票收盘价的时间序列，来分析个股和大盘指数之间的关联程度，从而区分大盘股与非大盘股；也可以通过计算个股与板块中其他股票之间的灰色关联度来判断个股是否应该属于这个板块，或者判断板块中的股票是否具有联动效应、板块的划分是否合理等。

2.4 灰色系统模型

灰色系统模型是以 GM(1, 1) 模型为基础的包括 GM(1, 1) 模型、GM(1, N) 模型一系列模型的总称。GM(1, 1) 模型的含义是一元（一个系统行为序列）一阶的灰色模型。

设系统原始序列 $X^{(0)} = (x^{(0)}(1), x^{(0)}(2), \dots, x^{(0)}(n))$ 为非负序列，原始序列的一次累加序列记为 $X^{(1)} = (x^{(1)}(1), x^{(1)}(2), \dots, x^{(1)}(n))$ ， $Z^{(1)} = (z^{(1)}(2), z^{(1)}(3), \dots, z^{(1)}(n))$ 为原始序列的紧邻均值生成序列，其中

$$z^{(1)}(k) = \frac{1}{2}[(x^{(1)}(k) + x^{(1)}(k-1))], \quad k = 2, 3, \dots, n$$

$$x^{(0)}(k) + ax^{(1)}(k) = b \quad (2-5)$$

称为 GM(1, 1) 模型的原始形式，

$$x^{(0)}(k) + az^{(1)}(k) = b \quad (2-6)$$

称为 GM(1, 1) 模型的基本形式。若参数列 $\hat{a} = [a, b]^T$ ，且

$$B = \begin{bmatrix} -z^{(1)}(2)1 \\ -z^{(1)}(3)1 \\ \vdots \\ -z^{(1)}(n)1 \end{bmatrix}, \quad Y = \begin{bmatrix} x^{(0)}(2) \\ x^{(0)}(3) \\ \vdots \\ x^{(0)}(n) \end{bmatrix}$$

则 GM(1, 1) 模型的参数列满足下述最小二乘估计

$$\hat{a} = (B^T B)^{-1} B^T Y \quad (2-7)$$

称

$$\frac{dx^{(1)}}{dt} + ax^{(1)} = b \quad (2-8)$$

为 GM(1, 1) 模型的白化方程, 白化方程的时间响应函数为

$$x^{(1)}(t) = (x^{(1)}(1) - \frac{b}{a})e^{-at} + \frac{b}{a} \quad (2-9)$$

其时间响应序列为

$$\hat{x}_1^{(1)}(k+1) = (x^{(0)}(1) - \frac{b}{a})e^{-ak} + \frac{b}{a}, \quad k=1, 2, \dots, n \quad (2-10)$$

还原值为

$$\hat{x}_1^{(0)}(k+1) = (1 - e^a)(x^{(0)}(1) - \frac{b}{a})e^{-ak}, \quad k=1, 2, \dots, n \quad (2-11)$$

GM(1, 1) 模型建模只用系统的行为特征序列, 而不用系统行为序列的相关因素序列。

其他比较常用的灰色系统模型有残差 GM(1, 1) 模型、GM(1, 1) 模型群、GM(1, N) 模型等。当 GM(1, 1) 模型建模的预测精度达不到要求时, 可以用系统序列的残差序列建立残差 GM(1, 1) 模型, 从而提高预测的精度。现实世界的系统一般是多变量系统, 而 GM(1, N) 模型是对系统行为特征数据序列和系统相关因素序列的建模, GM(1, N) 模型通过加入系统相关因素序列建模来提高模型的精度。

由于股票价格指数的收盘价是股票市场内外各种因素综合作用的结果, 体现了各种因素的综合平衡, 因此对股票的收盘价预测有较强的指导作用。各种灰色系统模型可以用来对股票指数的收盘价指数序列建模, 来预测股票的未来短期走势^[26]。

2.5 灰色灾变预测

灰色灾变预测实际上是对系统行为特征序列中异常值的预测, 灰色灾变预测通过把系统行为特征序列的指标集划分为上灾变集和下灾变集, 然后分别对其建立灰色 GM(1, 1) 模型, 从而预测系统的下一个或几个异常值可能出现的时间。

设原始序列为 $X = (x(1), x(2), \dots, x(n))$, 对于给定的上限值 ξ , 称序列 X 的所有不小于 ξ 的子序列

$$X_{\xi} = (x(q(1)), x(q(2)), \dots, x(q(m))) = \{x(q(i)) \mid x(q(i)) \geq \xi, i=1, 2, \dots, m\}$$

为上灾变序列。对于给定的下限值 ζ , 称序列 X 的所有不大于 ζ 的子序列

$$X_{\zeta} = (x(q(1)), x(q(2)), \dots, x(q(l))) = \{x(q(i)) \mid x(q(i)) \leq \zeta, i = 1, 2, \dots, l\}$$

为下灾变序列。称

$$Q^{(0)} = (q(1), q(2), \dots, q(m))$$

为灾变日期序列。灰色灾变预测就是通过对系统的灾变日期序列的研究，建立灾变日期序列的 GM(1, 1) 模型，从而寻找其规律性，并预测其未来的灾变日期。

$Q^{(0)}$ 的 1-AGO 序列记为

$$Q^{(1)} = (q(1)^{(1)}, q(2)^{(1)}, \dots, q(m)^{(1)})$$

$Z^{(1)}$ 为 $Q^{(1)}$ 的紧邻均值序列，则称

$$q(k) + ax^{(1)}(k) = b$$

为灾变 GM(1, 1) 模型。若 $\hat{a} = [a, b]^T$ 为参数序列的最小二乘估计，则其序号响应式为：

$$\hat{q}^{(1)}(k+1) = (q(1) - \frac{b}{a})e^{-ak} - (q(1) - \frac{b}{a})e^{-a(k-1)} = (1 - e^{-a})(q(1) - \frac{b}{a})e^{-ak}$$

灰色灾变预测可以对股票价格指数的灾变日期进行预测，进而预测股票价格指数的上涨或下跌的日期[田盈基于灰色理论的股市 GM(1, 1) 预测模型]。设股票指数阳线所对应的收盘价集合为阳变集（即上灾变集合），阳变集所对应的指标集称为上灾变日期集，反之，称股票指数阴线所对应的收盘价集合为阴变集（即下灾变集），阴变集所对应的指标集称为下灾变日期集。根据灰色灾变预测理论，分别建立上灾变日期序列和下灾变日期序列的 GM(1, 1) 模型，从而预测股票指数未来的几个上涨和下跌的日期。

2.6 本章小结

本章系统的介绍了灰色理论的内容及其在股票分析预测方面的应用。灰色系统理论经过二十多年的发展，逐渐形成了自己的学科体系和研究方法，并在社会、经济等系统中得到了广泛的应用。灰色序列算子主要通过一些灰色算子来消除环境噪声，其中灰色累加算子是灰色系统模型的基础。灰色关联分析是通过灰色关联度来判断系统序列之间的关联的紧密程度，灰色关联度可以用来分析个股和板块、个股和大盘之间关联的紧密程度。灰色系统模型是灰色系统理论的核心，它通过系统序列的累加序列和紧邻生成序列来建立灰色模型，是一个近似微分差分方程的模型；灰色系统模型可以通过对股票收盘价序列建模，来预测股票未来的价格。灰色灾变模型是灰色系统模型的一种应用，它把系统

序列的指标序列分离为上灾变集和下灾变集，并对上灾变集和下灾变集分别建立 GM (1, 1) 模型来预测系统的未来的一个或几个灾变日期；灰色灾变模型可以通过把股票的日期集分为阳变集和阴变集来预测股票的下一个或未来几个上涨或下跌的日期。

3 灰色神经网络模型

3.1 灰色模型与神经网络的几种融合方式

灰色系统理论是八十年代发展起来的一门新学科，灰色模型已广泛应用于工程技术、社会、经济、农业等各种复杂系统的预测中。灰色系统建模实际上对系统的行为特征序列建模，但灰色系统不具备并行计算的能力，序列数据的微小变动就会引起模型的重建。

人工神经网络模仿生物处理模式，通过大量的人工神经元的复杂连接来处理信息的并行处理连接网络。神经网络具有收敛性、鲁棒性、推广性等优点^[26]，神经网络的收敛性是指神经网络算法在输入训练样本后经过适度的训练可以收敛到正确权向量。神经网络的鲁棒性是指神经网络具有很好的抗干扰、噪声和自身损害的能力，个别神经元的损害对神经网络的学习能力并不会造成太大影响。神经网络网络的推广性是指神经网络对不属于训练样本集合的数据可以正确识别和分类。

神经网络主要有以下优点^[27]：（1）由于信息是分布存储于神经网络的各层神经元中的，因而神经网络具有很好的鲁棒性和容错性；（2）并行处理方法，神经网络可以并行的处理信息；（3）神经网络具有自学习、自组织、自适应性，使得神经网络可以处理不确定的系统；（4）神经网络通过对网络的训练可以使其逼近任意复杂的非线性关系。

我们可将灰色系统与神经网络技术的结合方式划分为以下几种^[28~30]：

（1）神经网络与灰色系统简单融合

在复杂系统中，对于系统中具有明显灰色特征的部分使用灰色系统模型来处理，而对于系统中无灰色特征的部分可以用神经网络来处理，两者之间是简单协作关系。

（2）串联型结合

灰色模型与神经网络在系统中按串行方式连接，在处理系统信息时，一方处理完信息后，交由另一方处理。

（3）用灰色系统辅助构造神经网络

在用神经网络求解灰色系统问题时，可用灰色系统中的确定性信息来改进

神经网络的学习算法。

(4) 神经网络与灰色系统的完全融合——灰色神经网络

灰色神经网络是灰色系统利用神经网络的结构来动态的调整其参数，从而具有了并行性。灰色神经网络是灰色系统模型与神经网络的有机结合，灰色神经网络在增加并行处理能力的同时，可以提高灰色系统模型的精度。

3.2 BP 神经网络模型

3.2.1 人工神经元模型

人工神经元模型是利用数学方法模拟生物神经元的模型，人工神经元的结构如图 3.1 所示。一个人工神经元通常包含以下三种基本要素：

(1) 一组连接权，其值表示所在连接的连接强度。

(2) 一个求和单元，用于求输入数据的加权和。

(3) 一个非线性激励函数，该激励函数起非线性映射作用，并把人工神经元的输出值限制在一定的取值范围之内(通常在 $[0, 1]$ 或 $[-1, 1]$ 之间)。

此外人工神经元还有一个阈值 θ_i ，人工神经元模型可用数学式表达为：

$$u_i = \sum_{j=1}^n w_{ij} x_j, \quad v_i = u_i - \theta_i, \quad y_i = f(v_i) \quad (3-1)$$

式中 x_1, x_2, \dots, x_n 为输入信号， $w_{i1}, w_{i2}, \dots, w_{in}$ 为神经元 i 的权值， u_i 为线性组合结果， θ_i 为阈值， $f()$ 为激励函数， y_i 为神经元 i 的输出。可以把人工神经元的输入向量的维数增加一维，即相当于增加了一个新的连接，其输入为 $x_0 = -1$ ，从而把阈值 θ_i 也包含了进来，从而式(3-1)可转化为：

$$u_i = \sum_{j=1}^n w_{ij} x_j, \quad y_i = f(u_i) \quad (3-2)$$

其中权值为 $w_{i0} = \theta_i$ 。

人工神经元的激励函数 $f()$ 通常有如下几种：

(1) 阈值函数：

$$f(u) = \begin{cases} 1, & u \geq 0 \\ 0, & u < 0 \end{cases}$$

(2) 分段线性函数:

$$f(u) = \begin{cases} 1, u \geq 1 \\ \frac{1}{2}(1+u), -1 < u < 1 \\ 0, u \leq -1 \end{cases}$$

(3) Sigmoid 函数:

$$\varphi(u) = \frac{1}{1 + \exp(-\alpha u)}$$

参数 α 可控制其斜率。




图 3.1 人工神经元结构

3.2.2 BP 神经网络结构

BP 算法，即误差方向传播算法，它是一种基于 δ 规则有监督的人工神经网络训练方法，采用 BP 算法的神经网络称为 BP 网络。BP 网络是一种前馈型神经网络，前馈型网络的网络结构见图 3.2。BP 神经网络一般由输入层、隐含层（或称隐藏层、隐层）和输出层组成。隐含层可以是一层，也可以是多层。BP 神经网络的学习过程由输入信号的正向传播和误差信号的反向传播两个过程组成。输入信号的正向传播即将输入信号沿着输入层逐层往前传播，前一层的输出信号作为下一层的输入信号，信号传至输出层时，计算网络输出与期望输出之间的误差，当误差达到要求范围时，训练结束。否则进入误差信号的反向传播过程，将误差信号沿与前向路径相反的路径反向传播，在传播的过程中逐层修改权值和阈值。如此反复，直到误差满足要求，或者达到最大迭代次数为止。




图 3.2 前馈型神经网络结构

由于 BP 神经网络采用的网络结构简单、泛化能力强，因而得到了广泛的应用，经过 20 多年的研究，BP 神经网络已经成为重要的人工神经网络之一，且已成功应用于模式识别、专家系统等领域。

3.2.3 BP 学习算法原理

我们可以通过以下方法训练网络，从而使一个三层的 BP 神经网络完成某个特定任务：

- (1) 向网络提供训练样例，训练样例包含网络的输入单元和网络的期望输出单元；
- (2) 确定网络允许的误差；
- (3) 训练网络，并根据实际输出和期望输出的误差来改变网络中所有的连接权值，直到满足给定的允许误差。

BP 学习算法是一种有监督的学习过程，它是根据给定的输入、输出样本对进行学习，并通过调整网络连接权值来体现学习的效果。设训练样例集合中有 N 个学习样例 (X_k, Y_k^*) ， $k=1, 2, \dots, N$ ，对实例 (X_k, Y_k^*) ，在正向传播过程中，输入向量 $X_k = (x_{1k}, x_{2k}, \dots, x_{nk})$ 从网络输入层的 n 个节点输入，经由隐含层逐层处理，在网络输出层得到网络实际的输出向量 $Y_k = (y_{1k}, y_{2k}, \dots, y_{mk})$ 。比较网络实际输出 Y_k 与期望输出 $Y_k^* = (y_{1k}^*, y_{2k}^*, \dots, y_{mk}^*)$ ，若所有训练样例的实际输出都达到允许的误差范围，则训练过程结束；否则，把网络实际输出 Y_k 与期望输出 Y_k^* 之间的误差由网络输出层沿着网络的前向路径向输入层反向传播，并在传播过程中

逐层修改各层节点之间的连接权值。

设 $I_{jk}^{(l)}$ 表示实例 k 输入后传播到第 l 层节点 j 的输入； $O_{jk}^{(l)}$ 表示第 l 层节点 j 的输出； $w_{ij}^{(l-1)}$ 为第 $l-1$ 层的节点 i 到第 l 层节点 j 之间的连接权值； $n^{(l-1)}$ 为第 $l-1$ 层的节点数； f 为神经元的传递函数，有：

$$I_{jk}^{(l)} = \sum_{i=1}^{n^{(l-1)}} w_{ij}^{(l-1)} O_{jk}^{(l-1)}$$

$$O_{jk}^{(l)} = f(I_{jk}^{(l)}) \quad (3-3)$$

实例 k 对网络节点 j 的期望输出 $O_{jk}^{*(l)}$ 与节点 j 的网络实际输出 $O_{jk}^{(l)}$ 的误差记为

$$E_{jk}^{(l)} = \frac{1}{2} (O_{jk}^{*(l)} - O_{jk}^{(l)})^2 \quad (3-4)$$

若第 l 层是网络的输出层，则有 $O_{jk}^{*(l)} = y_{jk}^*$ ， $O_{jk}^{(l)} = y_{jk}$ ，从而实例 k 的误差为

$$E_{jk}^{(l)} = \frac{1}{2} (y_{jk}^* - y_{jk}^{(l)})^2 \quad (3-5)$$

若对 N 个学习实例的任意一个实例 k 若有 $E_{jk}^{(l)} \leq \varepsilon$ ($j=1,2,\dots,m$)，则学习过程结束； ε 为指定的允许误差；否则，反向传播误差，按下式修改权值：

$$w_{ij}^{(l-1)} = w_{ij}^{(l-1)} + \Delta w_{ij}^{(l-1)}$$

$$\Delta w_{ij}^{(l-1)} = -\eta \frac{\partial E_{jk}^{(l)}}{\partial w_{ij}^{(l-1)}} \quad (3-6)$$

其中 η 为学习率， $0 < \eta < 1$ 。

由式 (3-3)、(3-4) 有

$$\frac{\partial E_{jk}^{(l)}}{\partial w_{ij}^{(l-1)}} = \frac{\partial E_{jk}^{(l)}}{\partial O_{jk}^{(l)}} \frac{\partial O_{jk}^{(l)}}{\partial I_{jk}^{(l)}} \frac{\partial I_{jk}^{(l)}}{\partial w_{ij}^{(l-1)}} = \delta_{jk}^{(l)} \frac{\partial I_{jk}^{(l)}}{\partial w_{ij}^{(l-1)}} = \delta_{jk}^{(l)} O_{jk}^{(l-1)} \quad (3-7)$$

其中

$$\delta_{jk}^{(l)} = \frac{\partial E_{jk}^{(l)}}{\partial I_{jk}^{(l)}} = \frac{\partial E_{jk}^{(l)}}{\partial O_{jk}^{(l)}} \frac{\partial O_{jk}^{(l)}}{\partial I_{jk}^{(l)}} = \frac{\partial E_{jk}^{(l)}}{\partial O_{jk}^{(l)}} f'(I_{jk}^{(l)}) \quad (3-8)$$

若第 l 层是输出层，则由式 (3-5) 可得

$$\frac{\partial E_{jk}^{(l)}}{\partial y_{jk}^{(l)}} = \frac{\partial E_{jk}^{(l)}}{\partial y_{jk}^{(l)}} = -(y_{jk}^* - y_{jk}) \quad (3-9)$$

由式 (3-8)、(3-9) 可得式 (3-10)

$$\delta_{jk}^{(l)} = -(y_{jk}^* - y_{jk}) f'(I_{jk}^{(l)}) \quad (3-10)$$

由式 (3-6)、(3-7) 和 (3-10) 可得式 (3-11)

$$\Delta w_{ij}^{(l-1)} = -\eta \delta_{jk}^{(l)} O_{jk}^{(l-1)} = \eta (y_{jk}^* - y_{jk}) f'(I_{jk}^{(l)}) O_{jk}^{(l-1)} \quad (3-11)$$

若第 l 层不是输出层, 第 l 层节点 j 的误差 $E_{jk}^{(l)}$ 对节点 j 的输出 $O_{jk}^{(l)}$ 的变化率为第 $l+1$ 层的 $n^{(l+1)}$ 个节点的各节点误差对其输出的变化率之和。若 $E_{qk}^{(l+1)}$ 表示第 $l+1$ 层的节点 q 的误差, $O_{qk}^{(l+1)}$ 表示该节点的实际输出, 则有

$$\frac{\partial E_{jk}^{(l)}}{\partial O_{jk}^{(l)}} = \sum_{q=1}^{n^{(l+1)}} \frac{\partial E_{qk}^{(l+1)}}{\partial O_{qk}^{(l+1)}} \quad (3-12)$$

对第 $l+1$ 层的节点 q , 类似第 l 层的节点 j 的式 (3-3)、(3-4) 和 (3-8), 有

$$I_{qk}^{(l)} = \sum_{j=1}^{n^{(l)}} w_{jq}^{(l)} O_{jk}^{(l)} \quad (3-13)$$

$$O_{qk}^{(l+1)} = f(I_{qk}^{(l+1)}) \quad (3-14)$$

$$E_{qk}^{(l+1)} = \frac{1}{2} (O_{qk}^{*(l+1)} - O_{qk}^{(l+1)})^2 \quad (3-15)$$

$$\delta_{qk}^{(l+1)} = \frac{\partial E_{qk}^{(l+1)}}{\partial I_{qk}^{(l+1)}} \quad (3-16)$$

因此, 可把式 (3-12) 表示为

$$\frac{\partial E_{jk}^{(l)}}{\partial O_{jk}^{(l)}} = \sum_{q=1}^{n^{(l+1)}} \frac{\partial E_{qk}^{(l+1)}}{\partial O_{qk}^{(l+1)}} = \sum_{q=1}^{n^{(l+1)}} \frac{\partial E_{qk}^{(l+1)}}{\partial I_{qk}^{(l+1)}} \frac{\partial I_{qk}^{(l+1)}}{\partial O_{qk}^{(l)}} = \sum_{q=1}^{n^{(l+1)}} \delta_{qk}^{(l+1)} w_{jq}^{(l)} \quad (3-17)$$

由式 (3-8) 和 (3-17) 得

$$\delta_{jk}^{(l)} = f'(I_{jk}^{(l)}) \sum_{q=1}^{n^{(l+1)}} \delta_{qk}^{(l+1)} w_{jq}^{(l)} \quad (3-18)$$

由式 (3-6)、(3-7) 和 (3-18) 可得

$$\Delta w_{ij}^{(l-1)} = -\eta \delta_{jk}^{(l)} O_{jk}^{(l-1)} \quad (3-19)$$

由式 (3-10) 计算输出层的各节点的 δ 值, 用式 (3-11) 或 (3-19), 就可以计算出各层各节点的权值的修改量 Δw 。

在网络的学习工程中, 训练样本全部输入一次称为一个训练周期, 训练通常是按训练周期进行的, 一次一个周期, 直到输出的训练误差小于某一给定的值。用 BP 算法训练网络时对权值的修改有两种方式, 一种是每输入一个训练样本, 根据训练误差修改一次权值; 另一种是批处理方式, 即输入所有训练样本, 完成一个训练周期后, 计算所有训练样本的平均误差, 并据此修改权值和权矩阵。

3.2.4 BP 反向传播算法

反向传播算法的步骤可描述如下:

(1) 输入 N 个学习实例 (X_k, Y_k^*) , $k=1, 2, \dots, N$ 。

(2) 根据学习实例的性质建立合理的 BP 神经网络结构。确定网络层数和各层节点数, 初始化各连接权矩阵的元素值。

(3) 输入停止误差 ε 和学习速率 η , 初始化学习实例序号 $k=1$, 迭代计算次数 $t=1$ 。

(4) 选取第 k 个学习实例 (X_k, Y_k^*) 。

(5) 由 X_k 进行正向传播计算。计算输入层各节点的输出为:

$$O_{jk}^{(l)} = f(x_{jk}), \quad j=1, 2, \dots, n$$

前向传播逐层计算隐含层至输出层中每个节点的输入和输出:

$$I_{jk}^{(l)} = \sum_{i=1}^{n^{(l-1)}} w_{ij}^{(l-1)} O_{ik}^{(l-1)}, \quad O_{jk}^{(l)} = f(I_{jk}^{(l)}), \quad l=2, \dots, L, \quad j=1, 2, \dots, n^{(l)}$$

(6) 计算神经网络输出层各节点的输出误差:

$$y_{jk} = O_{jk}^{(L)}, \quad E_{jk} = \frac{1}{2} (y_{jk}^* - y_{jk})^2, \quad j=1, 2, \dots, m$$

(7) 若对 N 个学习实例的每个实例均有 $E_{jk} \leq \varepsilon$, ($j=1, 2, \dots, m$), 则学习过程结束; 否则, 反向传播误差, 并修改连接权值矩阵。

(8) 误差反向传播。调整网络的第 $L-1$ 层隐含层到网络输出层的连接权

矩阵为:

$$\delta_{jk}^{(L)} = -(y_{jk}^* - y_{jk})f'(I_{jk}^{(L)})$$

$$\Delta w_{ij}^{(L-1)}(t) = -\eta \delta_{ij}^{(L)} O_{ik}^{L-1}$$

$$w_{ij}^{(L-1)}(t+1) = w_{ij}^{(L-1)}(t) + \Delta w_{ij}^{(L-1)}(t)$$

$$(j=1,2,\dots,m;i=1,2,\dots,n^{(L-1)})$$

反向逐层传播误差将神经网络各隐含层的连接权值矩阵调整为:

$$\delta_{jk}^{(l)} = f'(I_{jk}^{(l)}) \sum_{q=1}^{n^{(l+1)}} \delta_{qk}^{(l+1)} w_{jq}^{(l)}$$

$$\Delta w_{ij}^{(l-1)}(t) = -\eta \delta_{ij}^{(l)} O_{ik}^{l-1}$$

$$w_{ij}^{(l-1)}(t+1) = w_{ij}^{(l-1)}(t) + \Delta w_{ij}^{(l-1)}(t)$$

$$(l=L-1,\dots,2;j=1,2,\dots,n^{(l)};i=1,2,\dots,n^{(l-1)})$$

(9) $k=(k+1)\bmod N$, $t=t+1$, 转至步骤(4)。

3.3 GM(1,N)模型

GM(1, N)即一阶 N 个系统行为特征序列的灰色模型。现实世界中的系统大多是复杂的、具有灰色行为特征的多变量系统。

设 $X_1^{(0)} = (x_1^{(0)}(1), x_1^{(0)}(2), \dots, x_1^{(0)}(n))$ 为系统行为特征数据序列

$$X_2^{(0)} = (x_2^{(0)}(1), x_2^{(0)}(2), \dots, x_2^{(0)}(n))$$

$$X_3^{(0)} = (x_3^{(0)}(1), x_3^{(0)}(2), \dots, x_3^{(0)}(n))$$

.....

$$X_N^{(0)} = (x_N^{(0)}(1), x_N^{(0)}(2), \dots, x_N^{(0)}(n))$$

为系统行为特征序列的相关因素序列, $X_i^{(1)}$ 为 $X_i^{(0)}$ 的一次累加生成序列 ($i=0,1,2,\dots,N$), $Z_i^{(1)}$ 为 $X_i^{(1)}$ 的紧邻均值生成序列, 则称

$$x_1^{(0)}(k) + az_1^{(1)} = \sum_{i=2}^N b_i x_i^{(1)}(k) \quad (3-20)$$

为 GM(1, N) 模型。其中 b_i 称为驱动系数, $b_i x_i^{(1)}(k)$ 称为驱动项, $-a$ 称为系统发展系数, $\hat{a} = [a, b_1, b_2, \dots, b_N]^T$ 称为参数列。设

$$B = \begin{bmatrix} -z_1^{(1)}(2) & x_2^{(1)}(2) & \cdots & x_N^{(1)}(2) \\ -z_1^{(1)}(3) & x_2^{(1)}(3) & \cdots & x_N^{(1)}(3) \\ \vdots & \vdots & & \vdots \\ -z_1^{(1)}(n) & x_2^{(1)}(n) & \cdots & x_N^{(1)}(n) \end{bmatrix}, \quad Y = \begin{bmatrix} x_1^{(0)}(2) \\ x_1^{(0)}(3) \\ \vdots \\ x_1^{(0)}(n) \end{bmatrix}$$

则参数列 $\hat{a} = [a, b_1, b_2, \dots, b_N]^T$ 的最小二乘估计为:

$$\hat{a} = (B^T B)^{-1} B^T Y \quad (3-21)$$

而方程

$$\frac{dx^{(1)}}{dt} + ax_1^{(1)} = b_2 x_2^{(1)} + b_3 x_3^{(1)} + \cdots + b_N x_N^{(1)} \quad (3-22)$$

称为 GM(1, N) 模型

$$x_1^{(0)}(k) + az_1^{(1)} = \sum_{i=2}^N b_i x_i^{(1)}(k)$$

的白化方程, 或称为影子方程。

白化方程 $x_1^{(0)}(k) + az_1^{(1)} = \sum_{i=2}^N b_i x_i^{(1)}(k)$ 的解为

$$\begin{aligned} x^{(1)}(t) &= e^{-at} \left[\sum_{i=2}^N \int b_i x_i^{(1)}(t) e^{at} dt + x^{(1)}(0) - \sum_{i=2}^N \int b_i x_i^{(1)}(0) dt \right] \\ &= e^{-at} \left[x^{(1)}(0) - t \sum_{i=2}^N b_i x_i^{(1)}(0) + \sum_{i=2}^N \int b_i x_i^{(1)}(t) e^{at} dt \right] \end{aligned} \quad (3-23)$$

当 $X_i^{(1)} (i = 0, 1, 2, \dots, N)$ 变化幅度较小时, 该模型的近似时间响应序列为

$$\hat{x}_1^{(1)}(k+1) = (x_1^{(1)}(0) - \frac{1}{a} \sum_{i=2}^N b_i x_i^{(1)}(k+1)) e^{-a} + \frac{1}{a} \sum_{i=2}^N b_i x_i^{(1)}(k+1) \quad (3-24)$$

其中, $x_1^{(1)}(0)$ 取值为 $x_1^{(0)}(1)$ 。

累减还原式为

$$\hat{x}_1^{(0)}(k+1) = \hat{x}_1^{(1)}(k+1) - \hat{x}_1^{(1)}(k) \quad (3-25)$$

差分模拟式为

$$\hat{x}_1^{(0)}(k) = -az_1^{(1)}(k) + \sum_{i=2}^N b_i \hat{x}_i^{(1)}(k) \quad (3-26)$$

3.4 灰色神经网络模型

3.4.1 灰色神经网络结构

令： $d = \frac{1}{a} \sum_{i=2}^n b_{i-1} x_i^{(1)}(t)$ ，可将式 (3-24) 可以转化为：

$$x_1^{(1)}(t) = ((x_1^{(1)}(0) - d) - x_1^{(1)}(0) \cdot \frac{1}{1+e^{-a}} + 2d \cdot \frac{1}{1+e^{-a}}) \cdot (1+e^{-at}) \quad (3-27)$$

把变换后的式 (3-27) 映射到一个扩展的 BP 神经网络，可得到 n 个输入参数，1 个输出参数的灰色神经网络，网络拓扑结构如图 1 所示。




图 3.3 灰色神经网络拓扑结构

其中， t 为输入参数序号； $x_2^{(1)}(t), \dots, x_n^{(1)}(t)$ 为网络输入参数； $w_{21}, \dots, w_{2n}, w_{31}, \dots, w_{3n}$ 为网络权值； $x_1^{(1)}(t)$ 为网络预测值；LA、LB、LC、LD 分别表示灰色神经网络的四层。

令

$$\frac{2b_1}{a} = u_1, \frac{2b_2}{a} = u_2, \dots, \frac{2b_{n-1}}{a} = u_{n-1},$$

则网络初始化权值可以表示为：

$$w_{11} = a, w_{21} = -x_1^{(1)}(0), w_{22} = u_1, w_{23} = u_2, \dots, w_{2n} = u_{n-1}$$

$$w_{31} = w_{32} = \dots = w_{3n} = 1 + e^{-at}$$

LD 层中输出节点的阈值为:

$$\theta = (1 - e^{-at})(d - x_1^{(1)}(t))$$

3.4.2 灰色神经网络算法步骤

灰色神经网络算法的学习步骤如下^[31~41]:

步骤 1: 根据训练数据特征初始化网络结构, 初始化参数 $a, b_1, b_2, \dots, b_{n-1}$, 并根据 $a, b_1, b_2, \dots, b_{n-1}$ 的值计算 u 。

步骤 2: 根据网络权值定义计算 $w_{21}, \dots, w_{2n}, w_{31}, \dots, w_{3n}$

步骤 3: 对每一个输入序列 $(t, x_i^{(1)}(t)), t, i = 1, 2, \dots, n$, 计算每层输出。

LA 层: $a = w_{11}t$

LB 层:

$$b = f(w_{11}t) = \frac{1}{1 + e^{-w_{11}t}}$$

LC 层:

$$c_1 = bw_{21}, c_2 = x_2^{(1)}(t)bw_{22}, c_3 = x_3^{(1)}(t)bw_{23}, \dots, c_n = x_n^{(1)}(t)bw_{2n}$$

LD 层:

$$d = w_{31}c_1 + w_{32}c_2 + \dots + w_{3n}c_n - \theta x_1^{(1)}(t)$$

步骤 4: 计算网络预测输出与期望输出的误差, 并根据误差调整权值和阈值。

LD 层误差:

$$\delta = d - x_1^{(1)}(t)$$

LC 层误差:

$$\delta_1 = \delta(1 + e^{-w_{11}t}), \delta_2 = \delta(1 + e^{-w_{11}t}), \dots, \delta_n = \delta(1 + e^{-w_{11}t})$$

LB 层误差:

$$\delta_{n+1} = \frac{1}{1 + e^{-w_{11}t}} \left(1 - \frac{1}{1 + e^{-w_{11}t}}\right) (w_{21}\delta_1 + w_{22}\delta_2 + \dots + w_{2n}\delta_n)$$

再根据预测误差进行权值的调整。

LB 到 LC 的连接权值修改为:

$$w_{21} = -x_1^{(1)}(0), w_{22} = w_{22} - \mu_1\delta_2b, \dots, w_{2n} = w_{2n} - \mu_{n-1}\delta_nb$$

LA 到 LB 的连接权值修改为:

$$w_{11} = w_{11} + at\delta_{n-1}$$

调整阈值为：

$$\theta = (1 + e^{-\theta}) \left(\frac{w_{22}}{2} x_2^{(1)}(t) + \frac{w_{23}}{2} x_3^{(1)}(t) + \dots + \frac{w_{2n}}{2} x_n^{(1)}(t) - x_1^{(1)}(0) \right)$$

步骤 5：判断训练是否结束；若否，返回步骤 3。

3.4 本章小结

本章首先介绍了人工神经元模型、BP 神经网络和反向传播算法。由于 BP 网络具有自学习、自适应等优点，且可以任意逼近非线性关系，因而得到广泛的应用。GM (1, N) 模型是多系统序列的灰色系统模型，它可以通过对系统行为特征序列和相关序列建立灰色模型，来预测系统行为特征序列的发展趋势。本章最后介绍了灰色神经网络模型的结构和灰色神经网络算法步骤。由于灰色系统模型和 BP 神经网络各有所长，而灰色神经网络可以结合二者的优点，可以在少数据基础上对系统行为序列进行预测。

4 灰色神经网络模型在股票分析预测中的应用

4.1 上证综指日数据预测

4.1.1 日样本数据的选取

上证综指全称“上海证券交易所综合股价指数”，是国内外普遍采用的用于反应上海证券市场总体走势的指标，因而选取上证综指作为研究对象。

由于每日的收盘价是市场上的各种因素综合作用的结果，因此对收盘价的预测对投资者有较强的指导作用。本文选取的实验环境为 Matlab 7.0。选取上证综指的每日的收盘价、开盘价、最高价、最低价、成交量、成交额六项指标的归一化数据，建立灰色神经网络。建立的灰色神经网络结构为 1-1-6-1，即 LA 层有一个节点，输入为时间序列，LB 层有 1 个节点，LC 层有 6 个节点，从第 2 个到第 6 个输入分别为开盘价、最高价、最低价、成交量和成交额，输出为预测的收盘价。

选取上证综指 2010/08/02 至 2010/09/06 二十六个交易日的数据为训练数据，然后用 2010/09/07 至 2010/09/09 三个交易日的的数据评价网络的预测性能。选取的日样本数据集见表 4.1。样本数据来源于众成证券网上交易系统。

表 4.1 日样本数据

日期	开盘价	最高价	最低价	收盘价	成交量	成交额
2010.08.02	2635.81	2675.76	2633.65	2672.52	131925766	112156983296
2010.08.03	2678.79	2681.79	2626.72	2627	145598069	132380147712
2010.08.04	2620.5	2638.9	2589.99	2638.52	133762153	115185516544
2010.08.05	2636.24	2640.59	2606.62	2620.76	128048820	116955758592
2010.08.06	2618.71	2659.41	2598.91	2658.39	134772714	124990824448
2010.08.09	2656.36	2676.09	2650.4	2672.53	137100459	128442892288
2010.08.10	2672.79	2675.31	2594.34	2595.27	141535687	131287285760
2010.08.11	2587.61	2618.45	2586.02	2607.5	100286699	90162544640
2010.08.12	2584.92	2608.76	2570.96	2575.48	106481034	97353187328
2010.08.13	2576.69	2607.03	2564.84	2606.7	99461717	92588507136
2010.08.16	2603.79	2665.31	2596.77	2661.71	140100013	132298571776
2010.08.17	2663.18	2677.57	2654.01	2671.89	133731067	129954709504
2010.08.18	2674.5	2687.76	2654.41	2666.3	149040315	130297298944
2010.08.19	2669.43	2701.93	2659.3	2687.98	143211372	134944219136

4 灰色神经网络模型在股票分析预测中的应用

2010.08.20	2677.02	2683.29	2636.91	2642.31	133844304	121635749888
2010.08.23	2637.82	2656.12	2629.71	2639.37	97571923	92616466432
2010.08.24	2636.53	2667.17	2614.56	2650.31	123896078	108055461888
2010.08.25	2634.95	2645.5	2595.73	2596.58	122661110	109756227584
2010.08.26	2604.88	2616.96	2590.61	2603.48	89344083	82918244352
2010.08.27	2602.5	2613.49	2588.64	2610.74	76986973	75938496512
2010.08.30	2622.27	2656.35	2620.19	2652.66	123486988	122287529984
2010.08.31	2644.79	2647.25	2626.79	2638.8	119586757	125726466048
2010.09.01	2641.05	2662.88	2604.49	2622.88	146411847	140401836032
2010.09.02	2646.89	2659.98	2636.42	2655.78	134796040	143355281408
2010.09.03	2658.13	2660.54	2631.85	2655.39	139408992	147162251264
2010.09.06	2667.2	2698.6	2664.24	2696.25	160113842	162059878400
2010.09.07	2698.22	2704.93	2679.02	2698.36	122360269	124792127488
2010.09.08	2687.71	2695.84	2674.32	2695.29	121039753	131883130880
2010.09.09	2698.64	2698.64	2651.6	2656.35	143897600	157340008448

4.1.2 日收盘指数预测




图 4.1 日收盘指数的灰色神经网络训练预测结果

灰色神经网络的训练和预测结果如图 4.1 所示，可以看出灰色神经网络的

对上证综指日收盘价的预测与真实走势基本相符。

为了验证灰色神经网络的预测精度，本文对日收盘指数的灰色神经网络预测和 GM(1, N) 模型预测进行了预测结果的对比，其预测结果及误差分析见表 4.2，从中可以看出：灰色神经网络和 GM(1, N) 模型的单步预测结果都比较好，而预测精度灰色神经网络比 GM(1, N) 模型有所提高。

表 4.2 日收盘指数的预测结果比较

日期	实际收盘价	灰色神经网络预测	GM(1, N) 预测	灰色神经网络相对误差	GM(1, N) 相对误差
2010. 09. 07	2698. 36	2699. 52	2699. 64	0. 04%	0. 05%
2010. 09. 08	2695. 29	2711. 25	2713. 53	0. 59%	0. 67%
2010. 09. 09	2656. 35	2687. 18	2728. 70	1. 16%	2. 72%

4.2 上证综指周数据预测

4.2.1 周样本数据的选取

周 K 线图常被投资者看做中、短线的重要指标。投资者根据周 K 线图，以及对周 K 线走势的研判，来调整自己的投资策略，而收盘价又是其中最重要的数据指标。所以对周收盘价的预测可以指导投资者中、短线的投资策略。

选取上证综指 2010/08/02 至 2011/03/11 三十二周的周数据为样本数据，其中选取前二十九周数据为训练数据，后三周的数据用来评价灰色神经网络的预测性能。选取上证综指的周样本数据的收盘价、开盘价、最高价、最低价、成交量、成交额六项指标的归一化数据，建立灰色神经网络。选取的周样本数据集见表 4.3。

表 4.3 周样本数据

日期	开盘价	最高价	最低价	收盘价	成交量(万)	成交额(亿)
2010. 08. 06	2635. 81	2681. 79	2589. 99	2658. 39	647. 1	6016. 69
2010. 08. 13	2656. 36	2676. 09	2564. 84	2606. 7	584. 9	5398. 34
2010. 08. 20	2603. 79	2701. 93	2596. 77	2642. 31	699. 9	6491. 31
2010. 08. 27	2637. 82	2667. 17	2588. 64	2610. 74	510. 5	4692. 85
2010. 09. 03	2622. 27	2662. 88	2604. 49	2655. 39	663. 7	6789. 33
2010. 09. 10	2667. 2	2704. 93	2628. 83	2663. 21	675	7116. 18
2010. 09. 17	2665. 66	2703. 78	2583. 34	2598. 69	618. 2	6494. 78
2010. 09. 21	2601. 48	2607. 35	2573. 63	2591. 55	151. 4	1576. 36

4 灰色神经网络模型在股票分析预测中的应用

2010.09.30	2600.54	2656	2597.14	2655.66	385.5	4227.27
2010.10.08	2681.25	2747.8	2677.99	2738.74	154.8	1703.1
2010.10.15	2755.03	2971.16	2755.03	2971.16	1145	12478.48
2010.10.22	2985.46	3041.15	2931.91	2975.04	1111.4	11847.94
2010.10.29	2979.71	3073.38	2955.48	2978.83	967.2	11367.82
2010.11.05	2986.89	3142.59	2986.89	3129.5	1095.8	13165.31
2010.11.12	3140.4	3186.72	2975.16	2985.44	1149.2	13573.08
2010.11.19	2984.87	3016.13	2806.64	2888.57	816.2	8777.39
2010.11.26	2861.61	2904.97	2791.58	2871.7	702.1	7783.38
2010.12.03	2861.15	2881.16	2758.92	2842.43	584.9	6586.08
2010.12.10	2850.38	2884.53	2792.52	2841.04	501.5	5469.92
2010.12.17	2850.32	2939.05	2847.66	2893.74	574.1	6665.62
2010.12.24	2901.47	2917.2	2804.56	2835.16	567.5	6236.1
2010.12.31	2842.81	2876.81	2721.48	2808.08	463.7	4980.61
2011.01.07	2825.33	2868	2807.87	2838.8	461.8	5374.06
2011.01.14	2832.62	2847.36	2770.34	2791.34	448.7	4778.41
2011.01.21	2772.45	2780.94	2667.29	2715.29	475	4681.01
2011.01.28	2716.52	2759.44	2661.45	2752.75	453	4580.58
2011.02.01	2751.53	2805.05	2748.54	2798.96	177.1	1984.3
2011.02.11	2778.7	2835.41	2760.18	2827.33	319.3	3529.57
2011.02.18	2828.57	2939.28	2828.57	2899.79	744	8474.45
2011.02.25	2886.54	2944.41	2839.2	2878.56	650.7	7453.25
2011.03.04	2880.17	2944.46	2861.82	2942.31	714.2	8164.03
2011.03.11	2952.72	3012.04	2927.68	2933.8	712.9	8699.91

4.2.2 周收盘指数预测

周收盘指数的灰色神经网络训练和预测结果如图 4.2 所示，可以看出灰色神经网络的对上证综指周收盘价的预测与真实走势基本相符。为了验证灰色神经网络的预测精度，本文对周收盘指数的灰色神经网络预测和 GM(1, N)模型预测进行了预测结果的对比，其预测结果及误差分析见表 4.4，可以看出：灰色神经网络对周收盘指数的预测在预测精度上比 GM(1, N)模型有所提高。




图 4.2 周收盘指数的灰色神经网络训练预测结果

表 4.4 周收盘指数的预测结果比较

日期	实际收盘价	灰色神经网络预测	GM(1, N) 预测	灰色神经网络相对误差	GM(1, N) 相对误差
2010. 02. 25	2878. 56	2900. 03	2905. 17	0. 82%	0. 05%
2010. 03. 04	2942. 31	2998. 92	3012. 59	1. 92%	2. 39%
2010. 03. 11	2933. 80	3001. 53	3020. 03	2. 31%	2. 88%

4.3 上证综指月数据预测

4.3.1 月样本数据的选取

月 K 线图常被投资者看做中、长线的投资指标。投资者根据对月 K 线走势的研判，来调整自己的中、长线投资策略。对月收盘价的预测对投资者中、长线的投资决策有一定的指导作用。

选取上证综指 2008 年 9 月至 2011 年 2 月二十九个月的月数据为样本数据，其中选取前二十六个月的数据为训练数据，后三个月的数据用来评价灰色神经网络的预测性能。选取上证综指的月样本数据的收盘价、开盘价、最高价、最低价、成交量、成交额六项指标的归一化数据，建立灰色神经网络。选取的月

样本数据集见表 4.5。

表 4.5 月样本数据

日期	开盘价	最高价	最低价	收盘价	成交量(万)	成交额(亿)
2008.09	2380.47	2380.47	1802.33	2293.78	1230.9	8362.96
2008.10	2267.39	2267.39	1664.93	1728.79	1198.1	7559.89
2008.11	1713.76	2050.88	1678.96	1871.16	2066.5	12146.19
2008.12	1865.74	2100.81	1814.75	1820.81	2551.4	15970.41
2009.01	1849.02	2018.51	1844.09	1990.66	1497.6	9924.66
2009.02	2008.13	2402.81	1987.13	2082.85	3564.2	26790.24
2009.03	2066.23	2392.77	2037.02	2373.21	3163.2	25464.61
2009.04	2380.98	2579.22	2331.88	2477.57	3480.9	30558.66
2009.05	2486.69	2688.11	2486.23	2632.93	2699.6	24562.07
2009.06	2668.4	2997.27	2668.4	2959.36	3269.3	31341.14
2009.07	2950.17	3454.02	2947.69	3412.06	4540.7	48008.57
2009.08	3429.69	3478.01	2663	2667.75	3376.6	34258.29
2009.09	2649.17	3068.03	2639.76	2779.43	2948.1	28974.52
2009.10	2840.13	3123.46	2834.62	2995.85	2006.5	20426.44
2009.11	2933.82	3361.39	2923.52	3195.3	3754.2	39724.73
2009.12	3191.06	3334.01	3039.86	3277.14	3026.7	32596.53
2010.01	3289.75	3306.75	2963.89	2989.29	2674.3	29700.98
2010.02	2981.37	3067.52	2890.02	3051.94	1359.5	14527.19
2010.03	3057.01	3132.58	2963.44	3109.1	2352.3	25607.11
2010.04	3111.94	3181.66	2820.95	2870.61	2581.8	29182.61
2010.05	2821.35	2862.55	2481.97	2592.15	2049.8	19103.86
2010.06	2577.76	2598.9	2382.36	2398.37	1478.4	13235.73
2010.07	2393.95	2656.41	2319.74	2637.5	2195.8	17808.02
2010.08	2635.81	2701.93	2564.84	2638.8	2712.4	25079.33
2010.09	2641.05	2704.93	2573.63	2655.66	2250.7	23723.79
2010.10	2681.25	3073.38	2677.99	2978.83	3378.4	37397.33
2010.11	2986.89	3186.72	2758.92	2820.18	4043	46415.76
2010.12	2810.54	2939.05	2721.48	2808.08	2412.1	26821.73
2011.01	2825.33	2868	2661.45	2790.69	1936.9	20490.64
2011.02	2795.07	2944.41	2760.18	2905.05	1920	21860.77

4.3.2 月收盘指数预测

月收盘价的灰色神经网络训练和预测结果如图 4.3 所示，可以看出灰色神经网络的上证综指月收盘价的预测与真实走势基本相符。为了验证灰色神经

网络的预测精度，本文对月收盘指数的灰色神经网络预测和 GM(1, N) 模型预测进行了预测结果的对比，其预测结果及误差分析见表 4.6，从中可以看出：灰色神经网络对月收盘指数的预测比 GM(1, N) 模型的预测精度高。




图 4.3 月收盘指数的灰色神经网络训练预测结果

表 4.6 月收盘指数的预测结果比较

日期	实际收盘价	灰色神经网络预测	GM(1, N) 预测	灰色神经网络相对误差	GM(1, N) 相对误差
2010. 12	2808. 08	2801. 28	2704. 01	-0. 24%	-3. 71%
2011. 01	2790. 69	2896. 52	2690. 95	3. 79%	-3. 58%
2011. 02	2905. 05	2752. 65	2687. 98	-5. 25%	-7. 47%

4.4 本章小结

本章应用灰色神经网络，分别选取上证综指的日指数、周指数和月指数样本数据，对上证综指的日收盘指数、周收盘指数和月收盘指数进行了短期的预测。并比较了灰色神经网络与 GM(1, N) 模型的预测结果。研究表明预测的时间点距现在越近，预测越精确。随着时间跨度的增大，股票收盘指数的波动性

也越大，因而预测结果的相对误差也有增大的趋势。实验结果表明灰色神经网络在预测精度上优于 GM (1, N) 模型。

5 结论与展望

5.1 全文总结

股票价格指数综合反映了股票市场上所有股票的总体波动情况，对股票指数预测的准确预测对于投资者作出合理的决策具有重要的指导意义。

本文应用灰色神经网络对上证综指的收盘价格指数进行了短期的预测。灰色神经网络相对于其他模型，不需要太多的样本数据，也不需要样本数据服从某种特定的分布。本文的主要工作在于：

1. 改进了灰色神经网络的预测方法，将灰色神经网络应用于股票的短期预测。选取了收盘价、开盘价、最高价、最低价、成交量、成交额六项指标，建立灰色神经网络。
2. 分别对上证综指的日收盘指数、周收盘指数、月收盘指数进行了短期走势的预测。实验结果表明，随时股票收盘指数波动幅度的加大，预测误差有增大的趋势。灰色神经网络对较平稳的股票市场有较好的预测结果。
3. 比较了灰色神经网络与 $GM(1, N)$ 模型的预测结果，实验结果表明，灰色神经网络比 $GM(1, N)$ 模型的预测精度要高，更适合用来对股票短期走势进行预测。

5.2 工作展望

未来的研究工作可在以下几个方面展开：

1. 通过对灰色神经网络结构和参数的改进，并借鉴一些神经网络和其他模型组合的经验，以提高预测的精度。
2. 将灰色系统理论中的灰色关联分析、灰色聚类分析等方法引入股票分析预测中，从而形成一个基于灰色系统理论的股票分析预测的系统理论。
3. 将股票分析预测的各种理论结合起来，形成一个股票分析预测系统，为投资者提供合理的投资决策。

参考文献

- [1] Schumann M., Lohrbach T., Comparing Artificial Neural Networks with Statistical Methods within the Field of Stock Market Prediction[C]. Proceedings of the 26th Hawaii International Conference on System Science, 1993: 597~606
- [2] Corchado J., Fyfe C., Lees B. Unsupervised Learning for Financial Forecasting[C]. Proceedings of the IEEE/IAFE/INFORMS 1998 Conference on Computational Intelligence for Financial Engineering, 1998: 259~263
- [3] 田盈. 基于灰色理论的股市 GM(1, 1) 预测模型[J]. 数学的实践和认识, 2001, 31(5): 523~524
- [4] 陈海明, 李东. 灰色预测模型在股票价格中的应用[J]. 科研管理, 2003, 24(2): 28~31
- [5] 夏景明, 肖冬荣, 夏景虹, 贾佳. 灰色神经网络模型应用于证券短期预测研究[J]. 工业技术经济, 2004, 23(6): 109~111
- [6] 杨成, 程小玲, 殷旅江. 基于人工神经网络的上市公司股价预测[J]. 统计与决策, 2005(12): 106~108
- [7] 丁霞, 肖新平. 基于多因素的证券收益率灰色组合预测模型[C]. 第六届中国不确定系统年会, 2008: 169~173
- [8] 丛春霞, 季秀芳. 灰色预测在股票价格指数预测中的应用[J]. 中国统计, 2000, 19(5): 15~17
- [9] 薛世荣. 浅论我国股票市场弱式有效性[J]. 世界经济情况, 2007, (07): 43~46
- [10] 陈华友, 赵佳宝, 刘春林. 基于灰色关联度组合预测模型的性质[J]. 东南大学学报, 2004, 34(1): 130~140
- [11] 徐维维, 高风. 灰色算法在股票价格预测中的应用[J]. 计算机仿真, 2007, 24(11): 274~276
- [12] 王萍, 陈碧玉. 灰色理论模型在股价预测中的应用[J]. 自动化与信息工程, 2007, (03) 15~17
- [13] 刘思峰, 谢乃明等. 灰色系统理论及其应用(第四版)[M]. 北京: 科学出版社, 2008: 45~59
- [14] 党耀国, 刘思峰, 王正新等. 灰色预测与决策模型研究[M]. 北京: 科学出版社, 2009
- [15] 邓聚龙. 灰色预测与决策[M]. 武汉: 华中理工大学出版社, 2002: 41~48
- [16] 刘思峰. 灰色系统理论的产生与发展[J]. 南京航空航天大学学报, 2004, 36(2): 267~272
- [17] 方志耕, 刘思峰, 陆芳等. 区间灰数表征与算法改进及其 GM(1, 1) 模型应用研究[J], 中国工程科学, 2005. 2: 57~61

- [18] 肖新平, 灰色系统模型方法的研究. 华中科技大学博士论文, 2002
- [19] 谢乃明, 刘思峰. 一种新的弱化缓冲算子, 中国管理科学, 2003, 11(增刊):46~48
- [20] 党耀国, 刘思峰等. 关于弱化缓冲算子的研究, 中国管理科学, 2004, 12(2):108~111
- [21] 刘斌, 刘思峰, 党耀国. 基于灰色系统理论的时序数据挖掘技术. 中国工程科学, vol15, 2003(9):32~35
- [22] 党耀国, 刘思峰等. 基于动态多指标灰色关联决策的研究, 中国工程科学, 2005, 7(8):31~35
- [23] 党耀国, 刘思峰等. 灰色综合聚类评估模型的研究, 统计与决策, 2004, (10):4~6
- [24] 蒋宗礼. 人工神经网络导论[M]. 北京: 高等教育出版社, 2001: 5~12
- [25] 高隽. 人工神经网络原理及仿真实例[M]. 北京: 电子工业出版社, 2003: 37~48
- [26] 江志华. 灰色预测模型 $GM(1, 1)$ 及其在交通运输量预测中的应用[J]. 武汉理工大学学报. 2004, 28(2):305~307
- [27] 刘星, 迟建新等. 股票价格指数灰色系统预测与分析[J]. 数量经济技术经济研究. 2003(8): 128~131
- [28] 钟珞, 饶文碧, 邹承明. 人工神经网络及其融合应用技术[M]. 北京: 科学出版社, 2007, 91~110
- [29] 吕宏辉, 钟珞, 夏红霞. 灰色系统与神经网络融合技术探索. 微机发展, 2000(3):3~5.
- [30] 钟珞, 周兴刚. 灰色神经网络系统中对象消息通信的实现. 微机发展, 2001(5):6~7.
- [31] 蔡淑珍, 陈蕾, 陆阳. 灰色系统在基于神经网络入侵检测中的应用初探. 计算机工程与应用, 2003, 9:161~162, 187.
- [32] 章敬东, 刘小辉, 邓飞其等. 灰色神经网络组合算法在复杂非线性预测中的应用. 计算机工程与应用, 2003, 12:56~58.
- [33] 钟珞 白振刚等. 灰色神经网络建模优化及其应用. 计算机工程与应用, 2001, 9:33~34, 43.
- [34] 尚钢 钟珞 闫京生. 两种灰色神经网络模型及应用. 武汉理工大学学报, 2002, 12 (Vol. 24 No. 12):78~81.
- [35] 刘耦耕, 李圣清, 肖强晖. 多层前馈人工神经网络研究[J]. 湖南师范大学自然科学学报. 2004, 27(1): 26~30
- [36] 刘豹, 胡代平. 神经网络在预测中的一些应用研究[J]. 系统工程学报. 1999, 14(4): 338~344
- [37] 谢衷洁. 人工神经网络及其在金融预报中的应用[J]. 北京大学学报. 2001, 37(3): 421~425
- [38] 王维. 人工神经网络在非线性经济系统预测中的应用[J]. 系统工程学报. 2000, 15(2): 202~207
- [39] 吴成东, 王长涛. 人工神经元 BP 网络在股市预测方面的应用[J]. 控制工程. 2002, 27(3): 34~37

- [40] 欧邦才. 基于 BP 神经网络的经济预测方法[J]. 南京工程学院学报. 2004, 2(2): 11~14
- [41] 禹建丽, 孙增沂, Valeri Kroumov. 基于 BP 神经网络的股市建模与决策[J]. 系统工程理论与实践. 2003, 37(5): 17~21

致谢

本文是在导师王世卿教授的悉心指导和帮助下完成的,值此论文完成之际,首先对我的导师所付出的辛勤劳动和谆谆教诲表示衷心的感谢。同时,他孜孜不倦的工作精神、一丝不苟的治学风范以及正直磊落的为人态度都给了我深刻的影响,使我终生受益。

我真诚的感谢范明、叶阳东、李连友、王黎明、柴玉梅等教授,他们为我们传道解惑。对于您们的帮助,学生将永远铭记在心。对在平时学习和生活中给我无私的帮助和付出辛勤劳动的高明磊老师、庞军老师深表谢意。

感谢我最尊敬的父母,多年来在身后默默的给予我无微不至的支持。

感谢曹巧玲、王亚松、吴楠、田钊等同学,和你们在学习上共同探讨,生活上互相帮助,结下了深厚的友谊。

最后,向参加论文审阅、答辩的各位专家和老师表示感谢!

个人简历、在学期间发表的学术论文与研究成果

个人简历

姓名：王志远 出生年月：1984 年 10 月 河南温县人
2002 年 9 月～2006 年 7 月 西北农林科技大学 理学学士
2008 年 9 月～2011 年 7 月 郑州大学 工学硕士

在学期间发表的学术论文

王志远, 王世卿. 基于灰色神经网络的股票指数短期预测[J]. 微计算机信息. 已录用